

《机器学习工程师题库》

配套知识库 · 职业技能培训考核

题型：单选题、多选题、判断题

每章 5 道题，共 40 道题

第1章 机器学习概述与职业环境搭建 · 题库

1. 【单选题】以下哪种情况属于过拟合？ A. 训练集准确率 65%，测试集准确率 63% B. 训练集准确率 99%，测试集准确率 72% C. 训练集准确率 70%，测试集准确率 68% D. 训练集准确率 85%，测试集准确率 84% 答案：B

解析：过拟合的核心特征是模型在训练集上表现极好，但在测试集上表现明显变差。B 选项训练集 99% 而测试集 72%，差距 27 个百分点，是典型的过拟合。A、C 属于欠拟合，D 属于正常拟合。

2. 【单选题】在 sklearn 中，train_test_split 的 stratify 参数作用是？ A. 随机打乱数据顺序 B. 保证训练集和测试集中各类别比例与原始数据一致 C. 自动进行特征标准化 D. 设置随机种子保证可复现 答案：B 解析：stratify=y 会进行分层抽样，确保训练集和测试集中各类别的比例与原始数据集一致。这在类别不平衡时尤为重要。D 选项是 random_state 的作用。

3. 【单选题】特征标准化 (StandardScaler) 的公式是？ A. $x' = (x - \min) / (\max - \min)$ B. $x' = x / \max$ C. $x' = (x - \mu) / \sigma$ D. $x' = \log(x)$ 答案：C 解析：StandardScaler 执行 Z-score 标准化，公式为 $x' = (x - \mu) / \sigma$ ，其中 μ 是均值， σ 是标准差。A 是 MinMaxScaler 的公式。

4. 【多选题】以下关于机器学习 workflows 的说法，正确的是？ A. 数据收集应在模型训练之后进行 B. 测试集绝对不能参与任何训练或调参过程 C. 特征工程在模型选择之前进行 D. 模型部署后无需监控 答案：BC 解析：B 正确，测试集只能用于最终评估，参与训练会导致评估失效。C 正确，特征工程在模型选择之前。A 错误，数据收集是第一步。D 错误，部署后必须监控模型性能，防止概念漂移。

5. 【判断题】在 sklearn 中，fit_transform 用于训练集，transform 用于测试集，这是为了避免数据泄漏。 答案：正确 解析：fit_transform 会基于训练集计算统计量（如均值、标准差），然后转换数据。测试集只能用 transform，使用训练集计算出的统计量，避免测试集信息泄漏到训练过程中。

第2章 数据预处理与特征工程 · 题库

1. 【单选题】对于数值型特征的缺失值，以下哪种填充方法对异常值最鲁棒？ A. 均值填充 B. 中位数填充 C. 众数填充 D. 前向填充 答案：B 解析：中位数不受极端异常值影响。若数据中存在极大异常值，均值会被拉偏，而中位数保持稳定。均值对异常值最敏感。

2. 【单选题】One-Hot 编码时，若将 n 个类别的特征转换为 n 列，会导致什么问题？ A. 特征数量不足 B. 多重共线性（虚拟变量陷阱） C. 信息丢失 D. 内存溢出 答案：B 解析：One-Hot 编码保留 n 列会导致特征间完全线性相关（和为 1），产生多重共线性。应设置 `drop='first'` 保留 $n-1$ 列，或后续使用带正则化的模型。

3. 【单选题】以下哪种缩放方法对异常值最不敏感？ A. StandardScaler (Z-score 标准化) B. MinMaxScaler (归一化到 $[0,1]$) C. RobustScaler (基于四分位数) D. Normalizer (归一化到单位范数) 答案：C 解析：RobustScaler 使用四分位数（中位数和 IQR）进行缩放，对异常值完全不敏感。StandardScaler 和 MinMaxScaler 都会受异常值影响。

4. 【多选题】以下关于数据预处理的说法，正确的是？ A. 缺失值填充的统计量必须在训练集上计算 B. 决策树算法必须进行特征标准化 C. 高基数类别特征不适合直接使用 One-Hot 编码 D. 目标编码 (Target Encoding) 无需考虑数据泄漏 答案：AC 解析：A 正确，填充统计量必须在训练集上 fit，测试集仅 transform。C 正确，高基数特征 One-Hot 会产生数万列，应使用目标编码或特征哈希。B 错误，决策树基于排序分裂，不需要标准化。D 错误，目标编码若直接用全量数据计算会导致严重泄漏，应使用交叉验证方式。

5. 【判断题】在特征工程中，对目标变量取对数变换可以处理右偏分布，使残差更接近正态分布。 答案：正确 解析：对数变换是处理右偏数据的常用方法，可以压缩大值、拉伸小值，使分布更接近对称。这在回归任务中有助于满足线性回归的正态性假设，并降低异常值的影响。

第3章 线性模型：线性回归与正则化·题库

1. 【单选题】线性回归的损失函数通常采用？ A. 交叉熵损失 B. 均方误差 (MSE) C. Hinge 损失 D. 对数损失 答案：B 解析：线性回归使用均方误差 (MSE) 作为损失函数，衡量预测值与真实值之间差异的平方和。交叉熵用于分类问题，Hinge 损失用于 SVM。

2. 【单选题】关于 L1 正则化 (Lasso) 和 L2 正则化 (Ridge)，以下说法正确的是？ A. L1 正则化会使权重趋于小但不为零 B. L2 正则化可以产生稀疏解，用于特征选择 C. L1 正则化可能将某些特征的系数压缩到零 D. L1 和 L2 正则化对异常值的鲁棒性相同 答案：C 解析：L1 正则化 (Lasso) 由于使用绝对值惩罚，会在坐标轴上产生角点，使得某些特征的系数恰好为零，从而实现特征选择。A 描述的是 L2，B 描述的是 L1。

3. 【单选题】在 sklearn 中使用 GridSearchCV 时，cv=5 表示？ A. 将数据分成 5 份，取其中 1 份作为训练集 B. 将数据分成 5 份，进行 5 折交叉验证 C. 训练 5 个不同的模型 D. 测试集占 50% 答案：B 解析：cv=5 表示 5 折交叉验证，将数据分成 5 份，轮流用 4 份训练、1 份验证，共进行 5 次训练和验证，取平均结果。

4. 【多选题】以下关于正则化线性回归的说法，正确的是？ A. alpha 越大，正则化惩罚越强，模型越简单 B. Ridge 回归使用 L2 惩罚，Lasso 回归使用 L1 惩罚 C. ElasticNet 结合了 L1 和 L2 惩罚 D. 正则化线性回归不需要特征标准化 答案：ABC 解析：A 正确，alpha 越大惩罚越强。B 正确，Ridge 是 L2，Lasso 是 L1。C 正确，ElasticNet 是两者的线性组合。D 错误，正则化对特征尺度敏感，必须标准化，否则量纲大的特征会被不公平地惩罚。

5. 【判断题】在正则化线性回归中，alpha 越大，模型对训练数据的拟合程度越高。 答案：错误 解析：alpha 越大，正则化惩罚越强，模型越简单，对训练数据的拟合程度越低（偏差增大，方差减小），目的是防止过拟合。

第4章 分类算法：逻辑回归与朴素贝叶斯·题库

1. 【单选题】逻辑回归使用以下哪个函数将线性输出映射到概率？ A. ReLU B. Sigmoid C. Tanh D. Softmax 答案：B 解析：Sigmoid 函数 $\sigma(z) = 1/(1+\exp(-z))$ 将实数映射到 $(0,1)$ ，适合表示概率。Softmax 用于多分类，ReLU 是神经网络激活函数。

2. 【单选题】在 sklearn 的 LogisticRegression 中，参数 C 的含义是？ A. 正则化强度，越大惩罚越强 B. 正则化强度的倒数，越大惩罚越弱 C. 学习率 D. 最大迭代次数 答案：B 解析：C 是正则化强度的倒数 ($C = 1/\lambda$)，C 越大正则化越弱，模型越倾向于拟合训练数据。注意这与 Ridge/Lasso 中的 α 含义相反。

3. 【单选题】对于文本分类任务（词频特征），应该使用哪种朴素贝叶斯？ A. GaussianNB B. MultinomialNB C. BernoulliNB D. ComplementNB 答案：B 解析：MultinomialNB 假设特征服从多项式分布，适合离散计数数据如词频。GaussianNB 适合连续特征，BernoulliNB 适合二值特征。

4. 【多选题】以下关于逻辑回归和朴素贝叶斯的说法，正确的是？ A. 逻辑回归的损失函数是交叉熵损失 B. 朴素贝叶斯假设特征之间条件独立 C. 逻辑回归的决策边界是线性的 D. 朴素贝叶斯只能用于二分类 答案：ABC 解析：A 正确，逻辑回归使用交叉熵损失。B 正确，这是朴素贝叶斯的核心假设。C 正确，逻辑回归的决策边界是线性超平面。D 错误，朴素贝叶斯天然支持多分类。

5. 【判断题】拉普拉斯平滑 (Laplace Smoothing) 的作用是防止概率为 0 导致整个后验概率为 0。 答案：正确 解析：拉普拉斯平滑通过在分子加 1、分母加类别数，避免当某个特征在某类别中未出现时 $P(x_i|Y) = 0$ 导致整个后验概率连乘为 0 的情况。

第5章 距离模型：KNN 与 SVM · 题库

1. 【单选题】KNN 算法属于以下哪种学习类型？ A. 参数化学习 B. 非参数化学习 / 惰性学习 C. 深度学习 D. 强化学习 答案：B 解析：KNN 是一种非参数化和惰性学习算法。它没有显式的训练过程，不学习模型参数，而是直接记忆训练数据，预测时才进行计算。

2. 【单选题】在 SVM 中，参数 C 的作用是什么？ A. 核函数的带宽参数 B. 正则化参数，C 越小正则化越强 C. 支持向量的数量 D. 特征维度 答案：B 解析：C 是惩罚参数（正则化参数），C 越小对误分类的惩罚越轻，允许更大的间隔，正则化越强。注意这与逻辑回归中的 C 含义相同（都是正则化强度的倒数）。

3. 【单选题】SVM 中 RBF 核的 gamma 参数越大，模型的决策边界会怎样？ A. 越平滑 B. 越曲折，越容易过拟合 C. 越简单 D. 不受影响 答案：B 解析：gamma 越大，单个样本的影响范围越小，决策边界越曲折，越容易过拟合。gamma 越小，影响范围越大，边界越平滑。

4. 【多选题】以下关于 KNN 和 SVM 的说法，正确的是？ A. KNN 预测时计算量很大，不适合大规模实时预测 B. SVM 的最终模型只依赖于支持向量 C. KNN 只能用于分类任务 D. SVM 对特征尺度敏感，必须标准化 答案：ABD 解析：A 正确，KNN 预测需计算所有距离，时间复杂度 $O(nd)$ 。B 正确，非支持向量的拉格朗日乘子为 0，对模型无贡献。D 正确，SVM 基于距离计算，必须标准化。C 错误，KNN 也可用于回归（KNeighborsRegressor）。

5. 【判断题】K 值越大，KNN 的决策边界越复杂，越容易过拟合。 答案：错误 解析：K 值越大，参与投票的邻居越多，决策边界越平滑，模型越简单，越容易欠拟合。K 值越小，边界越复杂，越容易过拟合。

第6章 决策树与集成学习基础·题库

1. 【单选题】决策树中，CART 算法用于分类时默认使用的不纯度指标是？ A. 信息增益 B. 基尼指数 (Gini Index) C. 信息增益率 D. 交叉熵 答案：B 解析：sklearn 的 DecisionTreeClassifier 默认 criterion='gini'，使用基尼指数。ID3 使用信息增益，C4.5 使用信息增益率。

2. 【单选题】随机森林中 max_features='sqrt' 的含义是？ A. 每次分裂使用所有特征 B. 每次分裂随机选择 sqrt(n_features) 个特征 C. 特征重要性取平方根 D. 树的最大深度为平方根 答案：B 解析：max_features='sqrt' 表示每次分裂时，随机选择 sqrt(n_features) 个特征参与最优分裂点的搜索。例如 100 个特征时，每次只考虑 10 个特征，增加树之间的多样性。

3. 【单选题】Bagging 的主要目标是？ A. 降低偏差 B. 降低方差 C. 增加模型复杂度 D. 减少训练时间 答案：B 解析：Bagging 通过并行训练多个模型并取平均，主要降低模型的方差（随机性），提高稳定性。Boosting 主要降低偏差。

4. 【多选题】以下关于决策树和随机森林的说法，正确的是？ A. 决策树对特征缩放不敏感 B. 随机森林是 Bagging 的增强版，增加了随机特征选择 C. 决策树的叶节点越多，模型越不容易过拟合 D. 随机森林的 OOB 分数可用于估计泛化性能 答案：ABD 解析：A 正确，决策树基于排序分裂，不受尺度影响。B 正确，随机森林在 Bagging 基础上增加了特征子集随机选择。D 正确，OOB 分数使用未被采样的样本作为验证集。C 错误，叶节点越多树越复杂，越容易过拟合。

5. 【判断题】代价复杂度剪枝 (CCP) 是一种后剪枝方法。 答案：正确 解析：代价复杂度剪枝 (Cost Complexity Pruning) 先构建完整的树，然后通过 ccp_alpha 参数控制剪枝强度，属于后剪枝方法。预剪枝参数包括 max_depth、min_samples_split 等。

第7章 Boosting 算法：AdaBoost 与 GBDT · 题库

1. 【单选题】AdaBoost 中，如果某个基学习器的错误率大于 0.5，会发生什么？
A. 算法继续正常进行 B. 该学习器的权重 α_t 为负数，算法应停止或重新采样
C. 该学习器被赋予最高权重 D. 样本权重不再更新
答案：B 解析：当基学习器错误率 $\epsilon_t > 0.5$ 时， $\alpha_t = 0.5 * \ln((1-\epsilon_t)/\epsilon_t)$ 为负数，意味着该学习器比随机猜测还差。此时算法应停止或重新采样。

2. 【单选题】GBDT 与 AdaBoost 的核心区别是什么？
A. GBDT 使用更深的树 B. GBDT 通过拟合残差（负梯度）来逐步减小损失
C. GBDT 是并行训练的 D. GBDT 只能用于回归任务
答案：B 解析：AdaBoost 通过调整样本权重来关注错误样本；GBDT 通过拟合残差（负梯度）来逐步减小损失。GBDT 可以使用任意可微损失函数，更灵活。GBDT 是串行训练的，既可用于分类也可用于回归。

3. 【单选题】为什么 GBDT 的树深度通常设为 3~5？
A. 因为深树训练速度更快 B. 因为浅树（高偏差低方差）在 Boosting 框架下通过多轮迭代逐步提升，比深树更稳定
C. 因为 sklearn 限制了最大深度 D. 因为深树会导致内存溢出
答案：B 解析：GBDT 中每棵树只需拟合残差，不需要很强的拟合能力。浅树（高偏差低方差）在 Boosting 框架下通过多轮迭代逐步提升，比深树更稳定、更不易过拟合。

4. 【多选题】以下关于 Boosting 算法的说法，正确的是？
A. AdaBoost 的基学习器之间是串行训练的 B. GBDT 可以使用任意可微损失函数
C. AdaBoost 对噪声数据不敏感 D. GBDT 中 learning_rate 和 $n_estimators$ 存在权衡关系
答案：ABD 解析：A 正确，AdaBoost 串行训练，每轮依赖前一轮的样本权重。B 正确，GBDT 通过负梯度拟合，支持任意可微损失。D 正确， learning_rate 小则需要更多树。C 错误，AdaBoost 会持续关注难分样本，若存在噪声标签会导致过拟合。

5. 【判断题】增加 AdaBoost 的 $n_estimators$ 一定会提高测试集性能。
答案：错误 解析：迭代次数过多会导致过拟合（尤其对噪声数据）。应使用验证集监控性能，或使用早停策略。 $n_estimators$ 和 learning_rate 需要权衡设置。

第8章 XGBoost 与模型评估部署 · 题库

1. 【单选题】XGBoost 的 `early_stopping_rounds` 参数的含义是？ A. 最多训练多少轮 B. 如果在连续指定轮数内验证集性能没有提升，则停止训练 C. 每轮验证的频率 D. 学习率衰减的轮数
答案：B 解析：`early_stopping_rounds`

表示如果在连续指定轮数内，验证集性能没有提升，则停止训练。这自动确定了最优 `n_estimators`，防止过拟合。

2. 【单选题】对于类别极度不平衡的二分类问题，以下哪个指标最有参考价值？ A. 准确率 (Accuracy) B. AUC-ROC C. AUC-PR D. 均方误差 答案：C 解析：AUC-PR (精确率-召回率曲线下面积) 在正类稀少时更敏感，因为它关注精确率和召回率的权衡。类别极度不平衡时，AUC-ROC 可能虚高 (因为 FPR 分母很大)，而 AUC-PR 更能反映模型的真实性能。

3. 【单选题】时间序列数据应该使用哪种交叉验证策略？ A. K-Fold 交叉验证 B. StratifiedKFold C. TimeSeriesSplit D. Leave-One-Out 答案：C 解析：时间序列数据具有时间依赖性，普通 K-Fold 随机打乱会导致训练集中包含测试集的未来信息，造成泄漏。TimeSeriesSplit 确保训练集始终早于测试集，是时间序列的标准验证策略。

4. 【多选题】以下关于模型评估与部署的说法，正确的是？ A. 测试集只能用于最终评估，不能参与训练或调参 B. XGBoost 的 `gain` 重要性比 `weight` 重要性更能反映特征的真实重要性 C. 模型部署后无需监控，可以一直使用 D. `joblib` 可用于保存和加载训练好的 `sklearn` 模型 答案：ABD 解析：A 正确，测试集参与训练会导致评估失效。B 正确，`gain` 统计特征带来的平均损失减少量，`weight` 仅统计分裂次数。D 正确，`joblib` 是 `sklearn` 推荐的模型持久化方式。C 错误，生产环境必须监控模型性能，防止概念漂移导致性能下降。

5. 【判断题】在 XGBoost 中，`scale_pos_weight` 参数用于处理类别不平衡问题，其值通常设置为 $\text{sum(negative)} / \text{sum(positive)}$ 。答案：正确 解析： $\text{scale_pos_weight} = \text{sum(negative)} / \text{sum(positive)}$ 相当于给正类样本更高的权重，使模型更关注少数类。这是 XGBoost 处理类别不平衡的常用方法，等效于对正类进行过采样。